Projet 2 OC:

Analysez des données de systèmes éducatifs



- Start-up de la EdTech, nommée Academy
- Contenus de formation en ligne pour un public de niveau lycée et université
- Son but est de s'implanter à l'international

Analysez des données de systèmes éducatifs

Mark d'Academy me demande par mail à partir des données de la Banque mondiale **"EdStats All Indicator Query"** https://datacatalog.worldbank.org/dataset/education-statistics

- Quels sont les pays avec un fort potentiel de clients pour nos services?
- Pour chacun de ces pays, quelle sera l'évolution de ce potentiel de clients?
- Dans quels pays l'entreprise doit-elle opérer en priorité?

Analyse pré-exploratoire

- Comporte-t-il beaucoup de données manquantes, dupliquées ?
- Nombre de colonnes ? nombre de lignes ?
- Sélectionner les informations qui semblent pertinentes pour répondre à la problématique
- Déterminer des ordres de grandeurs des indicateurs statistiques classiques pour les différentes zones géographiques et pays du monde (moyenne/médiane/écart-type par pays et par continent ou bloc géographique)

Analyse pré-exploratoire

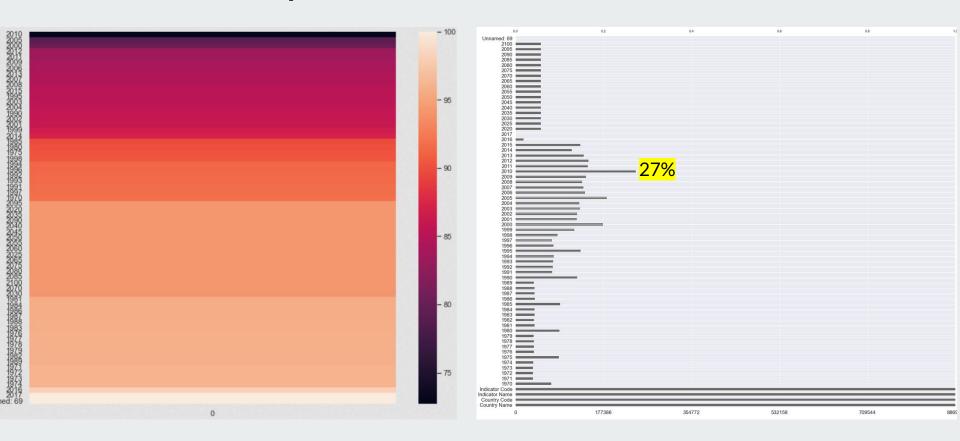
5 fichiers CSV

Nom/Nbr	Ligne	Colonne	Intérêt				
EdStatsData	886930	70	indicateurs, pays, années, données numérique continues et qualitatives nominales, bcp de données pertinentes				
EdStatsCountry	241	32	indicateurs, pays, notes, sources, peu de données pertinentes				
EdStatsCountry-Series	613	4	pays, notes, sources, peu de données peu pertinentes				
EdStatsFootNote	643638	5	pays, notes, sources, bcp de données, peu pertinentes				
EdStatsSeries	dStatsSeries 3665 21		indicateurs, notes, sources, peu de données, peu pertinentes				

Données dupliquées sur la colonne « Indicateurs » et informations

Data	columns (total	70 columns):		
#	Column	Non-Null Count	Dtype	Entrée [68]: df1=pd.DataFrame(data1, columns=['Country Name']) df2=df1.groupby(by="Country Name")
				len (df2)
0	Country Name	886930 non-null	object	Out[68]: 242
1	Country Code	886930 non-null	object	
2	Indicator Name	886930 non-null	object	Entrée [42]: len(data1['Country Name'].unique())
3	Indicator Code	886930 non-null	object	Out[42]: 242
4	1970	72288 non-null	float64	
5	1971	35537 non-null	float64	Entrée [43]: len(data1['Country Name'])
6	1972	35619 non-null	float64	Out[43]: 886930
7	1973	35545 non-null	float64	Entrée [69]: dfl=pd.DataFrame(data1, columns=['Indicator Name'])
8	1974	35730 non-null	float64	df2=df1.groupby(by="Indicator Name")
9	1975	87306 non-null	float64	len(df2)
10	1976	37483 non-null	float64	Out[69]: 3665
11	1977	37574 non-null	float64	Entrée [45]: len(data1['Indicator Name'].unique())
12	1978	37576 non-null	float64	The state of the s
13	1979	36809 non-null	float64	Out[45]: 3665
14	1980	89122 non-null	float64	Entrée [78]: data1['Indicator Name'].nunique(dropna=True)
15	1981	38777 non-null	float64	Out[78]: 3665
16	1982	37511 non-null	float64	5401.01. 5005
17	1983	38460 non-null	float64	Entrée [87]: len(data1['Indicator Name'])
18	1984	38606 non-null	float64	Out[87]: 886930
19	1985	90296 non-null	float64	<pre>dups = data1.pivot table(index = ['Country Name', 'Indicator Name'], aggfunc ='size')</pre>
20	1986	39372 non-null	float64	<pre>print (dups[dups>1])</pre>
				ries([], dtype: int64)

Données manquantes sur les colonnes « Années »



Données manquantes sur les colonnes « Années »



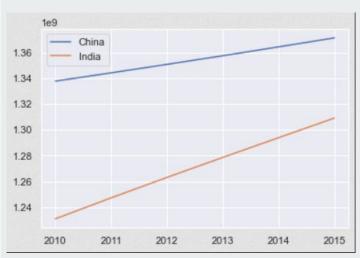
Données manquantes sur la colonne « Indicateurs »



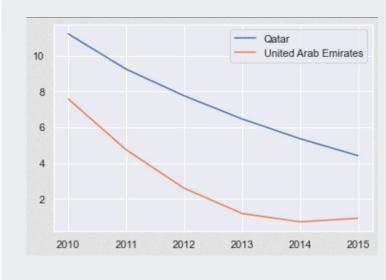
Statistiques sur les indicateurs sélectionnés

	Population, total	Population growth (annual %)	Internet users (per 100 people)	GDP per capita (current US\$)	Population of the official age for secondary education, both sexes (number)	School life expectancy, primary, both sexes (years)	Gross outbound enrolment ratio, all regions, both sexes (%)	Population, ages 0-14 (% of total)	Population of the official age for tertiary education, both sexes (number)	Mortality rate, under-5 (per 1,000)	Population, ages 13-19, total
count	2.160000e+02	216.000000	216.000000	216.000000	2.160000e+02	216.000000	216.000000	216.000000	2.160000e+02	216.000000	2.160000e+02
mean	3.366866e+07	1.426698	34.401353	15386.023056	5.970456e+06	5.989904	3.703767	28.926304	4.995565e+06	38.767147	4.701802e+06
std	1.288818e+08	1.558615	26.411632	22449.416483	1.565971e+07	1.041000	6.793553	10.273195	1.312045e+07	37.858081	1.558149e+07
min	1.053100e+04	-3.333512	0.250000	231.194326	1.310000e+03	2.461840	0.076720	11.935041	1.041000e+03	2.600000	1.006000e+04
25%	8.249985e+05	0.478990	10.000000	1619.189500	2.296595e+05	5.654540	0.534450	20.109418	1.591042e+05	10.375000	4.015512e+05
50%	6.166883e+06	1.264250	33.000000	6298.405565	9.037990e+05	5.973710	2.120460	28.808183	8.238175e+05	24.850000	1.534742e+06
75%	2.105204e+07	2.254904	53.075000	16621.446637	4.235514e+06	6.505418	3.379972	37.007866	3.312874e+06	54.075000	4.693412e+06
max	1.337705e+09	11.220686	93.390000	144246.368775	1.701458e+08	8.773300	55.501732	49.963344	1.296427e+08	208.000000	1.714163e+08

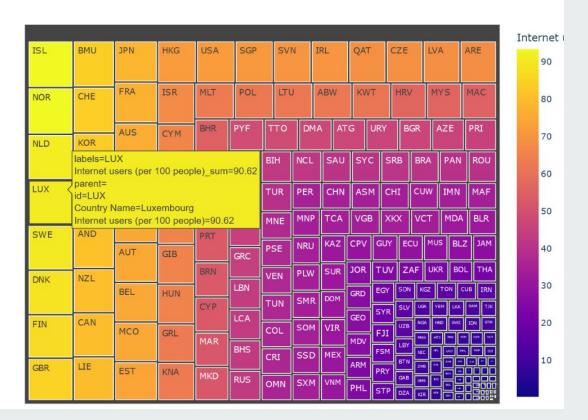


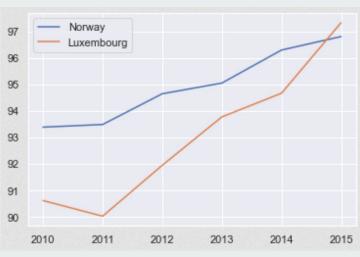




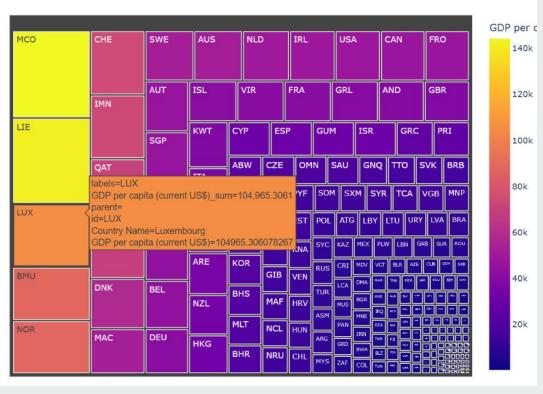


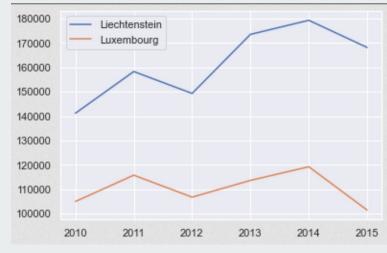
Internet users (per 100 people)



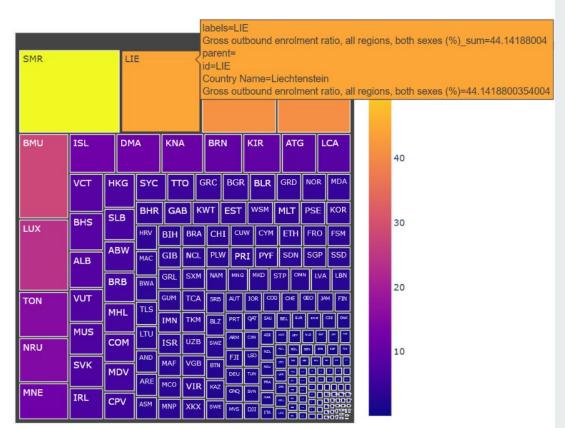


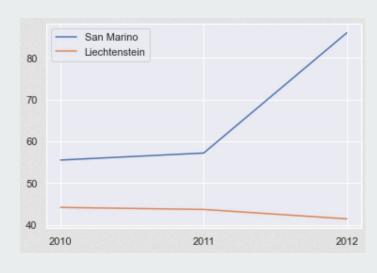
GDP per capita (current US\$)



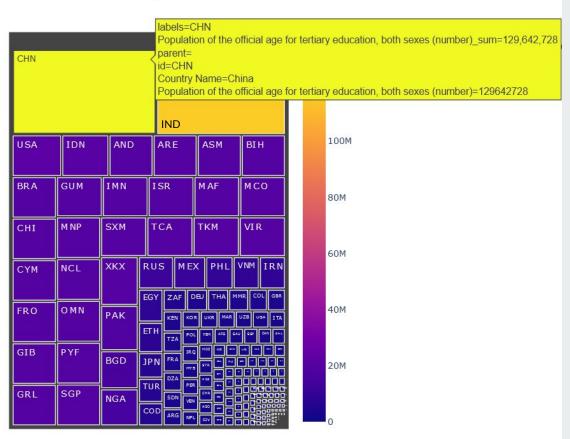


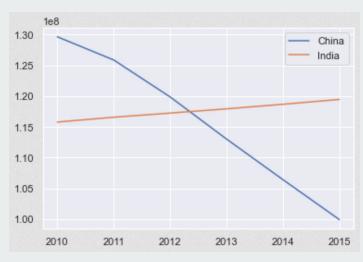
Gross outbound enrolment ratio, all regions, both sexes (%)

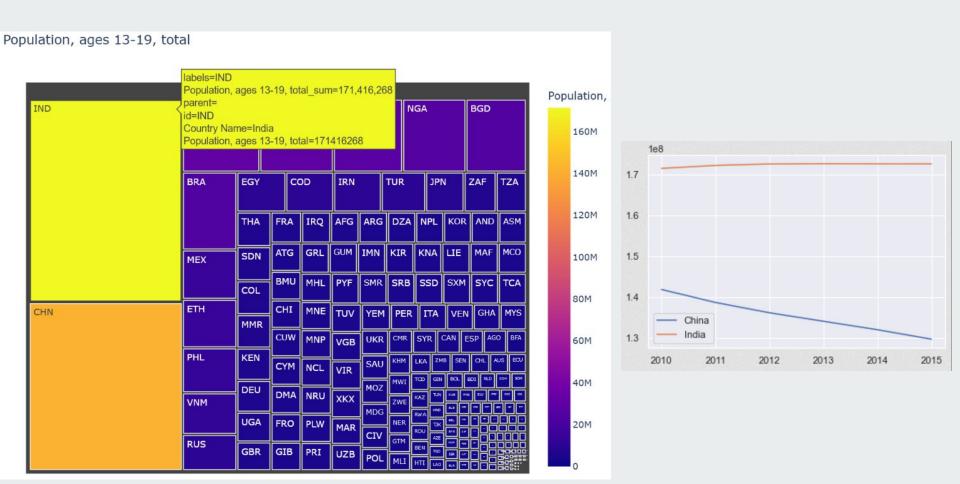




Population of the official age for tertiary education, both sexes (number)







Projet 2 OC : Analysez des données de systèmes éducatifs

Questions / Réponses